



# Structural Vibration Signal Denoising Using Stacking Ensemble of Hybrid CNN-RNN



- 구조 진동 신호를 활용한 새로운 모델을 제안

↳ 모델은 발걸음으로 인한 진동 신호를 분석하여 인간 및 동물의 움직임을 이해하는 데 활용

- 제안된 모델은

세 가지 주요 단계로 구성됨

1. 전처리 단계

↳ FFT(Fast Fourier Transform)와 웨이블릿 변환을 사용하여 신호의 특성을 추출

2. 하이브리드 모델링 단계

↳ LSTM과 CNN을 사용하여 잡음을 제거하고 신호의 특성을 압축

3. 앙상블 단계

↳ Fully-connected Neural Network를 사용하여 최종적으로 잡음이 제거된 신호 생성

## 1. Background and Introduction

- 해당 논문은 구조 진동 신호의 다양한 공학 분야에서의 응용과 함께, 이러한 신호에서 발생하는 노이즈를 효과적으로 제거(denoising)하는 새로운 방법을 제안
- 구조 진동 신호는 시민 공학(건축 및 토목 공학), 기계 공학 및 생물공학과 같은 다양한 분야에서 중요한 역할을 수행
  - 예를 들어, 시민 공학에서는 다리나 건물과 같은 구조물의 동적 행동을 모니터링하고, 이를 통해 지진이나 바람과 같은 하중에 대비
  - 또한, 기계 공학 분야에서는 터빈, 펌프, 엔진과 같은 기계의 건강을 모니터링하여 안전한 운영을 보장하고, 생물공학에서는 활동으로 인한 구조 진동을 통해 동물과

인간의 움직임을 분석하고 건강 상태를 파악

- 그러나 여러 원인에 의해 발생하는 노이즈는 신뢰성 있는 분석을 방해
  - 전기적 간섭, 환경 요인, 측정 오차 등으로 인해 발생 가능
  - 이러한 이유로, 정확한 분석을 위해서는 노이즈 제거가 필수적임
- 제안된 모델은 하이브리드 CNN-RNN stacking ensemble 구조를 사용하여 신호를 처리하고, 구조 역학을 모델링하기 위해 PDE/ODE를 활용
  - 모델은 복잡한 신호와 높은 노이즈 수준에서도 효과적으로 작동함을 검증하기 위해 다른 방법과의 성능을 비교하여 검증되었음

## 2. Dataset

- 구조 진동 신호의 실제값 획득은 상당히 어려움
  - PDE(편미분방정식)/ODE(상미분방정식) solver를 사용하여 구조 진동 시계열 데이터셋을 생성하는 방법을 제안함
- 발걸음으로 인한 구조 진동의 동역학을 중점적으로 다루며, 이를 Kirchhoff-Love 판의 응답으로 모델링

### ▼ Kirchhoff-Love 판

- 구조 역학에서 흔히 사용되는 모델 중 하나로, 판 구조물의 동적 행동을 모델링하는 데 활용
- 판이 얇고, 그 길이와 너비에 비해 매우 평평하며, 작은 변형에 노출될 때 적합
- Kirchhoff-Love 판 이론은 판의 변위와 회전을 설명하는 편미분 방정식(PDE)으로 구성
  - 이 방정식을 풀면 판의 동적 행동을 모델링할 수 있으며, 이를 통해 구조물의 진동 특성을 분석할 수 있음

$$D_i \nabla^2 \nabla^2 w_i(\mathbf{x}, t) - T_i \nabla^2 w_i(\mathbf{x}, t) = \delta(\mathbf{x}, t) - \rho_i h_i \ddot{w}_i(\mathbf{x}, t) - K_i \dot{w}_i(\mathbf{x}, t), \quad (1)$$

where  $w_i(\mathbf{x}, t)$  is the transverse deflection,  $D_i \sim \mathcal{N}(\mu_D, \sigma_D)$ ,  $T_i \sim \mathcal{N}(\mu_T, \sigma_T)$ ,  $\rho_i h_i \sim \mathcal{N}(\mu_{\rho h}, \sigma_{\rho h})$  and  $K_i \sim \mathcal{U}(a_U, b_U)$  are all parameters of the structure, governing the dynamical response subject to impulse  $\delta(\mathbf{x}, t)$ .

수학적 모델링

- 이를 위해, PDE 시스템의 해를 구함으로써 발걸음에 의해 유발된 진동의 현실적인 시뮬레이션을 생성




Figure 1: (a) A sample of foot-step induced floor vibration signal, normalized magnitude of vibration as a function of time [23, 24]. (b) An example of the signals generated based on Eqn. 1, displacement overlaid with a high level of supplemental Gaussian noise,  $w(t)$  as a function of time,  $t$  [s].

- 노이즈 제거를 위한 기초 데이터로 합성된 시계열을 사용하며, 이를 위해 가우시안 노이즈를 추가
- 합성 데이터의 신뢰성을 확인하기 위해 이전 연구에서 보고된 실제 측정값과의 비교를 수행
  - 결과적으로, 제안된 방법은 실제 측정값과 일치하는 합성 결과를 생성하는데 성공하였음

### 3. Methods, Results and Discussion

- 구조적 진동 신호의 양상불 및 순환 신경망(RNNs) 및 합성곱 신경망(CNNs) 예측을 결합한 스택킹 앙상블 모델을 제안

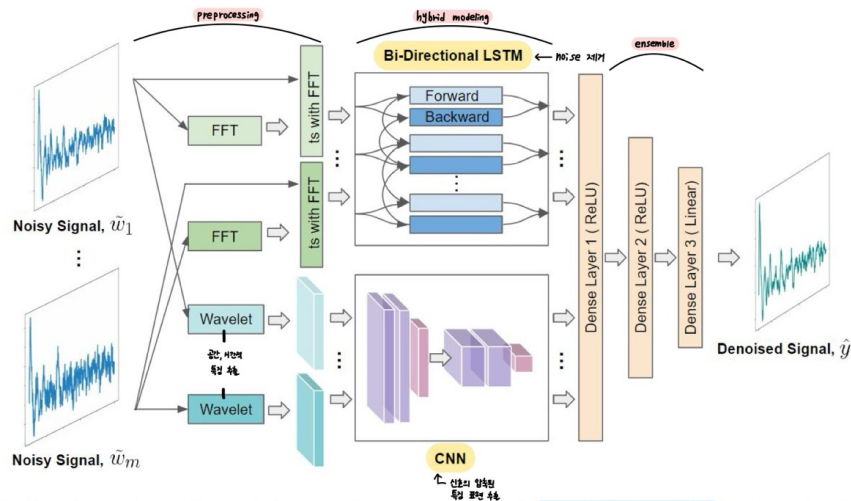


Figure 2: A schematic of the architecture for our proposed stacking ensemble of hybrid CNN-RNN model. The input to the model can consist of multiple noisy signals, ranging from  $\tilde{w}_1$  to  $\tilde{w}_m$ , while the output is a denoised signal, represented by  $\hat{y}$ .

- 해당 모델은 신호 처리의 세 단계로 구성

### 1. 전처리 단계

- 각 신호는 해당 Fast Fourier Transform (FFT) 결과와 결합되고, 각 이미지는 공간적 및 시간적 특징을 추출하기 위해 웨이블릿 변환을 거침

$$\mathbf{y}_{LSTM}^{[1]} = \bigcup_{i=1}^m \{\tilde{\mathbf{w}}_i, \mathcal{F}_{FFT}(\tilde{\mathbf{w}}_i)\},$$

$$\mathbf{y}_{CNN}^{[1]} = \bigcup_{i=1}^m \{\mathcal{F}_{WT}(\tilde{\mathbf{w}}_i)\},$$

### 2. 혼합 모델링 단계

- 양방향 LSTM 신경망이 FFT 결과와 결합된 노이즈가 있는 신호를 처리하고, CNN은 신호의 압축된 특징을 추출

$$\mathbf{y}_{LSTM}^{[2]} = \mathcal{F}_{LSTM}(\mathbf{y}_{LSTM}^{[1]}; \Theta_{LSTM}),$$

$$\mathbf{y}_{CNN}^{[2]} = \mathcal{F}_{CNN}(\mathbf{y}_{CNN}^{[1]}; \Theta_{CNN}),$$

### 3. 앙상블 단계

- 세 개의 완전 연결된 신경망 레이어가 최종 노이즈가 제거된 신호를 생성

$$\hat{\mathbf{y}} = \mathbf{y}^{[3]} = \mathcal{F}_{NN}(\mathbf{y}_{LSTM}^{[2]}, \mathbf{y}_{CNN}^{[2]}; \overset{\text{trainable}}{\Theta_{NN}}),$$

- loss 정의

- $L_2$  norm 활용

$$\mathcal{L}(\Theta) = \mathbb{E}_I \|\hat{\mathbf{y}} - \mathbf{I}\|^2 + \lambda_{LSTM} \mathbb{E} \|\Theta_{LSTM}\| + \lambda_{CNN} \mathbb{E} \|\Theta_{CNN}\| + \lambda_{NN} \mathbb{E} \|\Theta_{NN}\|$$

$$+ \sum_{i \neq j} \lambda \mathbb{E} \left\| \mathbf{y}_{LSTM}^{[2]\langle i \rangle} - \mathbf{y}_{LSTM}^{[2]\langle j \rangle} \right\|,$$

- 해당 논문의 전처리 접근 방식은 주파수 도메인과 시간 도메인의 특징을 유용하게 활용하여 구조적 진동 신호를 처리함
  - 이를 통해 다양한 노이즈 수준에서 일관된 성능을 보임
- 실험 결과

Table 1: Comparison of Models

Model	$\sigma_{\epsilon} = 0.1$			$\sigma_{\epsilon} = 0.2$		
	PSNR↑ [dB]	SNR↑ [dB]	WMAPE↓ [%]	PSNR↑ [dB]	SNR↑ [dB]	WMAPE↓ [%]
Ensemble	38.0	25.8	7.6	35.8	23.6	9.7
Total-Variance	31.2	19.0	15.8	24.2	11.8	29.4
Wiener	26.3	13.9	28.2	20.1	7.7	46.2
Savgol	27.6	15.4	24.1	22.2	10.1	40.4
PYWT	24.4	13.4	25.7	21.5	10.4	37.8

- 다른 노이즈 제거 알고리즘보다 우수한 성능을 보이며, 구조적 진동 신호의 노이즈 제거에 효과적인 것으로 입증됨

#### ▼ PSNR

- Peak Signal-to-Noise Ratio의 약자
- 영상 또는 신호의 품질을 측정하는 데 사용되는 일반적인 지표
- PSNR은 원본 신호와 노이즈가 추가된 또는 왜곡된 신호 간의 차이를 나타내는 신호와 노이즈 간의 간격을 측정
- 높을수록 더 나은 품질

#### ▼ SNR

- Signal-to-Noise Ratio의 약자
- 신호 대 노이즈 비율을 나타내는 지표
  - 신호의 강도와 노이즈의 강도 사이의 상대적인 크기
- 원본 신호의 신호 성분에 대한 신호의 세기와 추가된 노이즈의 세기 간의 비율로 정의
- 높은 SNR 값은 원본 신호에 비해 노이즈가 상대적으로 낮은 것을 나타내며, 이는 더 나은 신호 품질을 의미

#### ▼ WMAPE

- Weighted Mean Absolute Percentage Error의 약자
- 가중 평균 절대 백분율 오차를 나타내는 지표
  - 예측값과 실제값 간의 차이를 백분율로 표시한 후, 이를 가중 평균한 값
- 예측 오차를 상대적인 백분율로 표현하고, 예측값의 크기에 따라 가중치를 적용하여 오차를 측정
- WMAPE 값이 낮을수록 예측 모델의 정확성이 높다고 판단

## 4. Conclusion

- 해당 연구는 구조 진동 신호의 노이즈를 제거하기 위해 하이브리드 CNN-RNN 추적 앙상블 모델을 제안
- 모델은 전처리, CNN-RNN 하이브리드 모델링 및 앙상블 세 단계로 구성됨
- 제안된 모델은 여러 테스트 데이터셋에서 PSNR, SNR 및 WMAPE 측면에서 기존 알고리즘을 능가하는 성능을 보였음